Listino e contatore della sessione

Durata indicativa: 10 minuti. Si confronta il conto fatto a mano con quello del contatore di Claude Code.

Funzioni di Claude Code citate come da documentazione ufficiale (code.claude.com/docs), novembre 2026. Il modello dietro l'agente è un Claude, scelto dalla configurazione del proxy del laboratorio.

1. Il listino

Dollari per milione di token, listino pubblico di Anthropic consultato il 9 novembre 2026 (platform.claude.com/docs/en/about-claude/pricing) e di DeepSeek (api-docs.deepseek.com/quick_start/pricing).

Modello	Ingresso	Scrittura in cache (5 min)	Lettura dalla cache	Uscita
Haiku 5.5 (prompt fino a 100.000 token)	0,10	0,125	0,01	0,50
Haiku 5.5 (prompt oltre 100.000 token)	0,50	0,625	0,05	2,50
Sonnet 5.5	2	2,50	0,10	10
Opus 5.5	4	5	0,20	20
Fable 5.1	10	12,50	0,25	50
Sonnet 4.6 (modello precedente)	3	3,75	0,30	15
DeepSeek Flash, fuori orario di punta	0,15	come l'ingresso	0,003	0,60
DeepSeek Flash, orario di punta	0,30	come l'ingresso	0,006	1,20

Il listino cambia: prima di una stima vera, riapri la pagina del fornitore.

2. La formula

Per una sessione, con i token letti dal contatore:

```
costo = ( ingresso senza cache  x prezzo ingresso
        + scritti in cache      x prezzo scrittura
        + letti dalla cache     x prezzo lettura
        + uscita                x prezzo uscita ) / 1.000.000
```

3. Rifai il conto di un esempio

La documentazione di Claude Code mostra questo estratto del contatore (comando `/usage`, blocco "Session"):

```
Total cost:            $0.55
Usage by model:
   claude-sonnet-4-6:  1.2k input, 5.3k output, 940.0k cache read, 50.0k cache
write ($0.55)
```

Con i prezzi di Sonnet 4.6 della sezione 1, calcola il costo di ciascuna voce e il totale.

Voce	Token	Prezzo per milione	Costo
Ingresso	1.200		
Uscita	5.300		
Letti dalla cache	940.000		
Scritti in cache	50.000		
Totale			

Il totale torna con i 0,55 dollari del contatore? Quale voce pesa di più? Quale ha il prezzo più alto per token?

4. Il tuo contatore

Nella sessione che hai usato in questo incontro, scrivi `/usage` e leggi il blocco "Session". Annota:

Dato	Valore
Modello (come compare nel contatore)	
Token in ingresso	
Token in uscita	
Token letti dalla cache	
Token scritti in cache	
Costo totale mostrato	
Riga "Prompt cache" (se c'è): quota servita dalla cache	

Se una voce non compare, scrivilo: è un'informazione. In particolare, il costo che vedi è una stima: il contatore lo calcola in locale dai token con i prezzi che conosce, e potrebbe non coincidere con la spesa che il proxy registra per la tua chiave.

5. Stima e contatore

- Scegli nella calcolatrice il modello più vicino al tuo e prova a ricostruire la tua sessione: quanti giri ha avuto (le richieste), quanti token nuovi a giro?
- Confronta i token inviati in ingresso della calcolatrice con la somma di ingresso, lettura e scrittura del contatore. Di quanto differiscono?
- Cosa non è nella stima e potrebbe spiegare la differenza? Ragiona su ragionamento, subagenti, richieste in background, tentativi ripetuti.
- Se il contatore non mostra la cache: che cosa implica per il costo, e per chi dovrebbe verificarlo (il proxy, il fornitore)?

Le soluzioni le ha il docente.
